

Comparação de Técnicas de Agrupamento Aplicadas ao Perfil de Docentes do Ensino Superior Brasileiro

Larissa Alves Trevilato,
Fábio Martineli Gonçalves,
Samira Mota Gonçalves

*Universidade Federal de Uberlândia (UFU), Faculdade de Computação
Programa de Pós-Graduação em Ciência da Computação
Uberlândia, Minas Gerais, Brasil*

Abstract: Este trabalho apresenta uma análise exploratória de perfis docentes do ensino superior brasileiro utilizando técnicas de aprendizado não supervisionado, com foco nos algoritmos **K-means** e **Agglomerative Clustering**. A partir dos dados do Censo da Educação Superior de 2018, foram selecionadas variáveis relevantes relacionadas à idade, formação acadêmica, regime de trabalho e tipos de atuação docente. Após a etapa de pré-processamento e codificação das variáveis, o conjunto de dados foi utilizado como entrada para ambos os métodos de clusterização.

No caso do K-means, diferentes valores de k foram avaliados por meio dos métodos do cotovelo e do coeficiente de silhouette, sendo definida a estrutura final com três clusters. Os resultados mostraram a existência de três perfis distintos de docentes: um grupo majoritário formado por profissionais mais jovens focados no ensino presencial; um segundo grupo composto por docentes experientes com elevada titulação e forte atuação acadêmica; e um terceiro grupo formado por docentes sêniores, com predominância de doutores e participação expressiva em atividades de pesquisa. A análise por meio de PCA permitiu visualizar adequadamente a separação entre os grupos, reforçando a coerência dos clusters encontrados.

Para complementar a análise, foi aplicado o algoritmo **Agglomerative Clustering** (linkage *ward*) sobre uma amostra aleatória de 10.000 docentes, devido ao seu custo computacional quadrático. Os resultados indicaram uma estrutura de três agrupamentos compatível com a obtida pelo K-means, incluindo um cluster claramente isolado ao longo do primeiro componente principal. Entretanto, o coeficiente de silhouette obtido ($s \approx 0,17$) foi inferior ao do K-means, e a separação entre dois dos clusters mostrou-se mais difusa na projeção PCA, com maior sobreposição entre os grupos. Esses achados sugerem que, embora o método hierárquico identifique padrões semelhantes, o K-means apresenta melhor definição na estrutura dos clusters para este conjunto de dados.

Os resultados evidenciam como técnicas de agrupamento podem contribuir para a compreensão da composição e diversidade do corpo docente no Brasil, revelando padrões relevantes para estudos institucionais e formulação de políticas educacionais.

Index Terms: K-means, Agglomerative Clustering, aprendizado não supervisionado, mineração de dados educacionais, análise de dados, agrupamento de docentes, PCA, ensino superior.

1. Introdução

A análise de agrupamentos é uma das técnicas fundamentais em aprendizado de máquina não supervisionado, permitindo identificar padrões ocultos em conjuntos de dados sem rótulos explícitos. No contexto do Censo da Educação Superior de 2018, entender perfis de docentes é relevante para analisar a distribuição de experiência, escolaridade, atuação profissional e outras características estruturais do corpo docente brasileiro.

Neste trabalho, utilizamos o K-means e o Agglomerative Clustering para segmentar docentes por meio de atributos relacionados a idade, formação acadêmica, regime de trabalho e tipos

de atuação. O objetivo é identificar agrupamentos naturais presentes no conjunto de dados e caracterizar os perfis predominantes entre os docentes. Além disso, fazemos uma comparação de resultados obtidos entre os dois métodos escolhidos.

A escolha do K-means se justifica pelo seu bom desempenho em bases extensas, capacidade de gerar clusters bem definidos e facilidade de interpretação visual por meio de projeções via Análise de Componentes Principais (PCA) [1], [2], [3], [4].

A escolha do Agglomerative Clustering complementa a análise ao permitir avaliar uma abordagem hierárquica de agrupamento, capaz de revelar relações estruturais entre os dados que não são capturadas por métodos como o K-means [5]. Diferentemente do K-means, que depende da inicialização de centróides e da definição explícita do número de clusters, o Agglomerative constrói uma hierarquia de fusões sucessivas que oferece uma visão mais detalhada da similaridade entre instâncias [6]. Esse método é particularmente útil para verificar a robustez da estrutura de agrupamentos encontrada, bem como para avaliar se existem padrões globais consistentes independentemente da técnica empregada [7].

2. Descrição do Conjunto de Dados

A base utilizada corresponde a 397.893 docentes registrados no Censo da Educação Superior 2018 e possui, inicialmente, 41 colunas. Após limpeza e filtragem de colunas relevantes, a base final usada no agrupamento incluiu 384.474 docentes e 15 variáveis, das quais:

- 1 variável numérica: idade;
- 4 variáveis categóricas ordinais: escolaridade, regime de trabalho, sexo, raça/cor;
- 10 variáveis binárias: indicando participação em atividades como pesquisa, ensino presencial, pós-graduação, extensão e gestão.

As variáveis foram normalizadas e codificadas via *One-Hot Encoding* para compatibilidade com os algoritmos escolhidos, que operam sobre dados numéricos e calcula distâncias euclidianas.

A Tabela I apresenta as 15 variáveis finais utilizadas no processo de clusterização:

TABLE I: Variáveis selecionadas para o processo de clusterização.

Variável	Tipo	Descrição
NU_IDADE	Númerica	Idade do docente em anos.
TP_SEXO	Categórica ordinal	Sexo do docente (masculino/feminino).
TP_COR_RACA	Categórica ordinal	Autodeclaração de raça/cor.
TP_ESCOLARIDADE	Categórica ordinal	Maior titulação alcançada pelo docente.
TP_REGIME_TRABALHO	Categórica ordinal	Regime de trabalho.
IN_DEFICIENCIA	Binária	Indica se o docente possui algum tipo de deficiência.
IN_ATUACAO_EAD	Binária	Atuação em cursos na modalidade EAD.
IN_ATUACAO_EXTENSAO	Binária	Atuação em atividades de extensão.
IN_ATUACAO_GESTAO	Binária	Atuação em funções administrativas ou de gestão.
IN_ATUACAO_GRAD_PRESENCIAL	Binária	Atuação em cursos presenciais de graduação.
IN_ATUACAO_POS_EAD	Binária	Atuação em cursos de pós-graduação na modalidade EAD.
IN_ATUACAO_POS_PRESENCIAL	Binária	Atuação em cursos de pós-graduação presenciais.
IN_ATUACAO_SEQUENCIAL	Binária	Atuação em cursos sequenciais.
IN_ATUACAO_PESQUISA	Binária	Participação em atividades de pesquisa.
IN_SUBSTITUTO	Binária	Indica se o docente atua como professor substituto.

Essa seleção criteriosa assegurou que o conjunto de atributos utilizados refletisse informações relevantes para o perfil acadêmico e profissional dos docentes, evitando ruídos e garantindo que o processo de clusterização fosse conduzido de forma eficiente e interpretável.

3. Metodologia

Os experimentos realizados neste trabalho foram conduzidos utilizando o ambiente Google Colab e a implementação da execução dos algoritmos K-means e Agglomerative Clustering sobre o

dataset de entrada foi realizada integralmente em *Python*, empregando-se as seguintes bibliotecas principais: *Pandas* para manipulação tabular e limpeza dos dados; *NumPy* para operações numéricas; *Scikit-learn* (*sklearn*) para execução dos algoritmos K-means e Agglomerative Clustering, normalização dos atributos (via *StandardScaler*), codificação das variáveis categóricas (*OneHotEncoder*), criação de pipelines de pré-processamento e aplicação da Análise de Componentes Principais (PCA) para fins de visualização; e *Matplotlib* e *Seaborn* para construção dos gráficos e das representações visuais dos clusters.




Fig. 1: Fluxo horizontal da metodologia utilizada no estudo.

As etapas de pré-processamento incluíram:

- Remoção de atributos irrelevantes (identificadores e informações redundantes).
- Exclusão de registros com valores ausentes.
- Normalização de variáveis numéricas usando *StandardScaler*.
- Codificação One-Hot das variáveis categóricas.

3.1. Seleção de Atributos

A etapa de seleção de atributos teve como objetivo identificar, entre as 41 variáveis originais do conjunto de docentes, aquelas que de fato contribuiriam para a formação de agrupamentos significativos pelo algoritmo K-means. A remoção de variáveis irrelevantes ou redundantes é particularmente importante em cenários de alta dimensionalidade, pois atributos pouco informativos podem introduzir ruído, aumentar o custo computacional e dificultar a interpretação dos clusters formados [8].

Inicialmente, foram excluídas todas as variáveis de identificação, como *CO_IES*, *CO_DOCENTE_IES* e *ID_DOCENTE*, pois essas informações não descrevem características intrínsecas dos docentes e poderiam interferir no cálculo das distâncias. Também foram removidas variáveis administrativas ou geográficas que não se relacionam diretamente ao perfil acadêmico, tais como país, estado e município de nascimento. Além disso, atributos redundantes — aqueles que poderiam ser inferidos por outros ou que apareciam em múltiplas formas no dataset — foram desconsiderados.

Durante a análise exploratória, observou-se que algumas variáveis apresentavam proporção elevada de dados faltantes. A variável *IN_BOLSA_PESQUISA*, por exemplo, possuía mais de 50% de valores ausentes, inviabilizando sua utilização. Outras variáveis binárias relacionadas à atuação docente também continham ausências, embora em menor escala. Dessa forma, optou-se por remover todas as variáveis com grande quantidade de valores faltantes e, posteriormente, excluir os registros que ainda continham valores ausentes nos atributos selecionados. Como resultado dessa filtragem, o conjunto final passou de 41 para 15 variáveis relevantes, preservando informações essenciais sobre perfil acadêmico, atuação profissional e características importantes dos docentes. Além da redução das variáveis, essa etapa também reduziu o dataset original de 397.893 para 384.474 registros, o que não causou impacto significativo na quantidade de registros e eliminou totalmente a problemática do *missing values*.

As variáveis selecionadas foram organizadas em três grupos:

- (i) numéricas, representadas apenas pela idade;
- (ii) categóricas ordinais, como escolaridade, regime de trabalho, sexo e raça/cor;
- (iii) variáveis binárias indicando diferentes tipos de atuação acadêmica.

As variáveis numéricas foram normalizadas por meio do *StandardScaler*, assegurando que diferenças de escala não influenciassem o cálculo das distâncias euclidianas. A principal variável numérica utilizada foi a idade do docente (`NU_IDADE`), por exemplo, cuja faixa variava significativamente entre indivíduos (de aproximadamente 18 a mais de 80 anos). A normalização dessa variável evitou que valores absolutos elevados impactassem desproporcionalmente a formação dos clusters.

As variáveis categóricas foram transformadas utilizando codificação *One-Hot*, convertendo cada categoria em uma representação binária independente, compatível com o modelo. Entre essas variáveis estão, por exemplo, o sexo do docente (`TP_SEXO`), a raça/cor (`TP_COR_RACA`), o regime de trabalho (`TP_REGIME_TRABALHO`) e a escolaridade (`TP_ESCOLARIDADE`). Cada uma dessas variáveis possui categorias distintas — como “masculino” e “feminino” no caso de `TP_SEXO`, ou “mestrado” e “doutorado” no caso de `TP_ESCOLARIDADE` — que foram convertidas em colunas binárias individuais. Essa transformação permite que o algoritmo K-means aplique adequadamente a medida de distância em atributos originalmente não numéricos.

Ao final, todas as variáveis transformadas foram concatenadas em uma matriz de alta dimensionalidade, adequada para o processo de clusterização pelo K-means. Para fins exclusivos de visualização e interpretação, foi aplicada a Análise de Componentes Principais (PCA), permitindo projeções bidimensionais e tridimensionais sem interferir no treinamento do modelo. Essas projeções facilitaram a interpretação dos agrupamentos detectados, preservando a estrutura interna dos dados.

4. Execução do K-MEANS

O algoritmo K-means foi aplicado ao conjunto de dados totalmente pré-processado, composto por 384.474 docentes representados em um espaço vetorial de 29 atributos numéricos resultantes da normalização e codificação das 15 variáveis originais.

No K-means, inércia é a soma das distâncias quadráticas dos pontos ao centróide de seu cluster [9]. Quanto menor a inércia, mais próximos os pontos estão do centro do grupo, ou seja, mais compacto ele é. A inércia diminui conforme o número de clusters aumenta, por isso ela é usada para avaliar se adicionar novos clusters realmente melhora o agrupamento [9].

O índice de silhouette mede o quão bem cada ponto está inserido em seu cluster. Ele compara: a distância média do ponto para outros pontos do mesmo grupo (coesão), e a distância média dele para pontos do cluster mais próximo (separação). O valor varia de -1 a 1 e quanto maior a silhueta, melhor o agrupamento: os clusters ficam mais separados e bem definidos. Por isso esse índice ajuda a escolher o número ideal de clusters [10].

O método do cotovelo é uma forma de escolher quantos clusters usar no K-means. Para isso, calculamos a inércia do modelo para vários valores de k . A inércia sempre diminui quando aumentamos o número de clusters, mas depois de certo ponto a melhora passa a ser muito pequena. Esse ponto de mudança na curva, que forma um “cotovelo”, indica um valor de k que equilibra boa separação entre os grupos e simplicidade do modelo [11].

Para determinar o valor apropriado de k , foram avaliados valores entre 2 e 8 clusters em que foi utilizado o dois critérios complementares para a definição do melhor k : o método do cotovelo, baseado na análise da inércia intra-cluster (coesão interna dos clusters) e o coeficiente de silhouette, que quantifica simultaneamente a coesão interna e a separação entre clusters [12], [13].

O método do cotovelo apresentou uma queda acentuada da inércia até $k = 3$ e uma estabilidade a partir desse valor, mostrando uma convergência da coesão interna com $k = 3$; já a análise do coeficiente de silhouette apresentou o melhor valor com $k = 2$, com o resultado para um valor 3 tendo um resultado bem próximo do ponto ótimo. Entretanto, no método do cotovelo, a coesão

TABLE II: Valores de Silhouette e Inércia para diferentes valores de k no K-means (amostra de 50.000 docentes).

k	Silhouette	Inércia
2	0.6979	214870.15
3	0.2115	182556.23
4	0.1990	167470.40
5	0.1888	155961.60
6	0.1847	149928.81
7	0.1883	145622.73
8	0.1804	140729.61
9	0.1801	137062.34

para $k = 2$ foi baixa, quando comparado a k valendo 3, portanto foi escolhido $k = 3$, que apresentou melhor equilíbrio entre interpretabilidade e separação estrutural dos clusters.

O algoritmo foi executado utilizando a implementação do *Scikit-learn* que foi inicializado com `k-means++` para melhorar a estabilidade, reduzir o risco de cair em mínimos locais e melhorar o processo de convergência. O processo foi repetido 10 vezes ($n_{init} = 10$), pois como o K-means é sensível à inicialização é recomendável repetir o processo para reduzir sensibilidade a inicializações. Finalizando as configurações iniciais, foi setado o `random_state = 42` para reprodutibilidade, sendo o modelo final foi: K-means ($k = 3$, `random_state = 42`, $n_{init} = 10$).

Após convergência, cada docente foi atribuído a um dos três clusters obtidos, no qual o coeficiente de silhouette resultante foi 0,21; valor considerado moderado para bases de alta dimensionalidade e forte heterogeneidade estrutural, indicando separação razoável entre os grupos. A distribuição final é apresentada na tabela III.

TABLE III: Distribuição dos Clusters Resultantes do K-means

Cluster	Quantidade de docentes
0	207.374
1	40.243
2	136.857

Para inspecionar a separação geométrica entre os clusters, foi aplicada Análise de Componentes Principais (PCA) preservando a maior variância possível nas projeções. A visualização 2D, mostrada na 2, revela que tem-se três regiões distintas: Cluster 0 e Cluster 2 que ocupam regiões próximas, porém separáveis ao longo dos componentes principais; e Cluster 1, composto por docentes mais experientes e de maior titulação, forma um grupo bem isolado no eixo do primeiro componente (PC1), o que reforça sua distinção estrutural em relação aos demais.

A análise descritiva dos clusters revelou algumas diferenças, tais como:

- Cluster 0: possui docentes mais jovens (idade média de 37,3 anos) com atuação predominante no ensino presencial, maioria de especialistas e mestres com baixa participação em atividades de pesquisa, extensão ou pós-graduação ;
- Cluster 1: possui docentes experientes (idade média de 44,9 anos) com alta qualificação acadêmica (maioria de doutores) e maior envolvimento em pesquisa, gestão e atividades de pós-graduação;
- Cluster 2: possui docentes mais velhos (idade média de 55,6 anos) e fortemente titulados (predominância elevada de doutores) e participação significativa em atividades de pesquisa.

Os resultados obtidos com o algoritmo K-means demonstram que o conjunto de docentes do ensino superior brasileiro apresenta uma estrutura compatível com três grupos principais, cada um associado a um estágio distinto de maturidade profissional e envolvimento acadêmico. Essa segmentação surgiu de forma consistente tanto a partir das métricas quantitativas quanto das análises descritivas das variáveis internas a cada cluster.

Primeiramente, a escolha de $k = 3$ revelou-se adequada ao equilíbrio entre coesão intra-




Fig. 2: Análise de Componentes Principais (PCA) para os resultados do K-MEANS.

cluster e separabilidade entre grupos. Embora o coeficiente de silhouette tenha apresentado valor moderado (0,21), tal resultado é esperado em bases de grande porte, alta dimensionalidade e composição heterogênea. Ainda assim, a visualização em PCA demonstrou separações significativas entre os clusters, especialmente ao longo do primeiro componente principal, indicando que os grupos possuem diferenças claras de perfil profissional.

A análise dos atributos por cluster evidencia um gradiente de senioridade e especialização. O Cluster 0 agrupa docentes mais jovens, predominantemente mestres ou especialistas, com forte atuação em atividades básicas de ensino presencial. Esse padrão é compatível com estágios iniciais da carreira acadêmica, nos quais a dedicação ao ensino tende a ser predominante. Em contraste, o Cluster 1 reúne docentes de maior experiência, com maior proporção de doutores e atuação ampliada em pesquisa, gestão e pós-graduação. Já o Cluster 2 representa o grupo mais maduro, com idade média mais elevada, forte concentração de doutores e maior envolvimento em pesquisa, caracterizando o ápice da trajetória acadêmica.

O gráfico de radar (3) permite comparar os perfis médios de cada cluster em várias variáveis ao mesmo tempo, todas normalizadas na escala de 0 a 1. Os clusters 1 e 2 apresentam formatos mais amplos, indicando valores médios mais altos em diferentes atributos. Já o Cluster 0 aparece quase como um ponto no centro do radar porque, após a normalização, seus valores médios ficam próximos dos menores valores observados em todas as variáveis. Assim, o radar mostra de forma visual que o Cluster 0 possui baixa intensidade relativa nos atributos analisados, enquanto os demais clusters apresentam perfis mais expressivos.

Esses resultados sugerem que o K-means foi capaz de capturar dimensões importantes da progressão profissional docente, mesmo sem acesso explícito a variáveis temporais ou de trajetória. É relevante notar que atributos binários associados à atuação profissional contribuíram de maneira expressiva para a distinção entre clusters, indicando que a diversidade de atividades desempenhadas pelo docente é um fator estruturante no agrupamento.




Fig. 3: Radar

5. Execução do Agglomerative Clustering

O método **Agglomerative Clustering**, da família de algoritmos hierárquicos, foi empregado como abordagem complementar ao K-means, permitindo comparar a segmentação dos docentes a partir uma perspectiva também não supervisionada, porém não baseada em centróides. Diferente do K-means, o algoritmo aglomerativo constrói uma hierarquia de agrupamentos através de um processo *bottom-up*, no qual cada observação inicia como um cluster independente, e pares de clusters são fundidos iterativamente conforme um critério de similaridade.

Para este estudo, utilizou-se o método de ligação *Ward*, que minimiza a variância intra-grupo a cada fusão, tornando-o particularmente adequado para dados numéricos pré-processados por padronização e codificação *one-hot*.

Devido ao custo computacional quadrático do Agglomerative Clustering $O(n^2)$, sua aplicação sobre todo o conjunto de 384.474 docentes seria inviável em ambiente computacional limitado, como o Google Colab. Assim, conforme prática recomendada na literatura [14], [15], [16], realizou-se o agrupamento sobre uma amostra aleatória estratificada de 10.000 observações, mantendo a representatividade estatística dos perfis docentes.

O modelo foi ajustado com $n = 3$ clusters, visando permitir comparação direta com os resultados do K-means. Após o ajuste, aplicou-se PCA para projeção bidimensional dos agrupamentos, possibilitando análise visual e interpretação qualitativa das regiões de separação entre os grupos.

TABLE IV: Distribuição dos Clusters Resultantes do agglomerative clustering

Cluster	Quantidade de docentes
0	4.933
1	1.051
2	4.016

Os resultados indicaram uma estrutura de clusters semelhante à obtida pelo K-means, com um grupo numeroso de docentes jovens e com atuação predominantemente no ensino presencial; um segundo grupo composto por docentes de maior idade e elevada qualificação; e um terceiro grupo intermediário com características mistas. No entanto, o coeficiente de Silhouette obtido (*silhouette* = 0.1702) foi inferior ao observado para o K-means, sugerindo menor coesão interna e maior sobreposição entre grupos. A projeção via PCA corroborou esse comportamento, revelando zonas de transição menos definidas entre os dois primeiros clusters.

Apesar das limitações, o Agglomerative Clustering forneceu uma visão complementar relevante, evidenciando a consistência geral da estrutura de três perfis docentes, ao mesmo tempo em que destacou a maior robustez do K-means para dados de alta dimensionalidade com grande número de instâncias.




Fig. 4: Análise de Componentes Principais para os resultados do agglomerative clustering.

6. Conclusões

Este estudo demonstrou a utilidade de métodos de agrupamento na análise exploratória do corpo docente brasileiro, tomando como referência os registros do Censo da Educação Superior de 2018. A abordagem baseada em K-means foi capaz de identificar três perfis marcantes de docentes, diferenciados principalmente por idade, nível de escolaridade e padrões de atuação em ensino, pesquisa e extensão. Esses resultados foram reforçados por visualizações em PCA, que evidenciaram separações estruturais coerentes entre os grupos.

A presença de três grupos bem distintos sugere interpretações relevantes para políticas institucionais: identificação de perfis, avaliação da distribuição de formação acadêmica entre regiões ou instituições, e análise de demandas específicas de capacitação e incentivos para docentes em diferentes estágios da carreira.

O Agglomerative Clustering foi utilizado de forma complementar, oferecendo uma perspectiva hierárquica dos agrupamentos. Apesar da maior complexidade computacional, o método confirmou a tendência geral observada no K-means, ainda que com menor separabilidade entre as instâncias quando avaliado pelo coeficiente de silhouette. Essa convergência entre métodos distintos sugere que a organização dos perfis docentes representam padrões reais presentes na base.

Assim, conclui-se que a clusterização é uma ferramenta valiosa para sintetizar e interpretar grandes volumes de dados educacionais, permitindo identificar grupos de docentes com características similares e fornecendo subsídios para reflexões institucionais e formulação de políticas públicas. Trabalhos futuros podem incorporar variáveis adicionais, técnicas de redução de dimensionalidade não lineares ou métodos mais robustos de clusterização para ampliar a compreensão desses padrões.

References

- [1] A. L. Jiménez-Preciado, S. Cruz-Aké, and F. Venegas-Martínez, "Identification of patterns in CO₂ emissions among 208 countries: K-means clustering combined with PCA and non-linear t-SNE visualization," *Mathematics*, vol. 12, no. 16, p. 2591, 2024, accessed: Dec. 9, 2025. [Online]. Available: <https://doi.org/10.3390/math12162591>
- [2] S. Juanita and R. D. Cahyono, "K-means clustering with comparison of elbow and silhouette methods for medicines clustering based on user reviews," *Jurnal Teknik Informatika (JUTIF)*, vol. 5, no. 1, pp. 283–289, 2024, accessed: Dec. 9, 2025. [Online]. Available: <https://doi.org/10.52436/1.jutif.2024.5.1.1349>
- [3] S. Mulyaningsih and J. Heikal, "K-means clustering using principal component analysis (PCA): Indonesia multi-finance industry performance before and during Covid-19," *Asia Pacific Management and Business Application*, vol. 11, no. 2, pp. 131–142, 2022, accessed: Dec. 9, 2025. [Online]. Available: <https://doi.org/10.21776/ub.apmba.2022.011.02.1>
- [4] E. S. Vasconcelos, L. A. da Silva, and F. A. dos Santos, "Análise multidimensional da agricultura: uso de PCA e clustering para identificação de padrões e eficiência em práticas agrícolas," *Caderno Pedagógico*, vol. 21, no. 13, p. e12679, 2024, accessed: Dec. 9, 2025. [Online]. Available: <https://doi.org/10.54033/cadpedv21n13-388>
- [5] F. Murtagh and P. Contreras, "Algorithms for hierarchical clustering: An overview," *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 2, no. 1, pp. 86–97, 2012, accessed: Dec. 9, 2025. [Online]. Available: <https://doi.org/10.1002/widm.53>
- [6] D. Xu and Y. Tian, "A comprehensive survey of clustering algorithms," *Annals of Data Science*, vol. 2, no. 2, pp. 165–193, 2015, accessed: Dec. 9, 2025. [Online]. Available: <https://doi.org/10.1007/s40745-015-0040-1>
- [7] M. Brun, C. Sima, J. Hua, J. Lowey, B. Carroll, E. Suh, and E. R. Dougherty, "Model-based evaluation of clustering validation measures," *Pattern Recognition*, vol. 40, no. 3, pp. 807–824, 2007, accessed: Dec. 9, 2025. [Online]. Available: <https://doi.org/10.1016/j.patcog.2006.06.026>
- [8] J. Li, K. Cheng, S. Wang, F. Morstatter, R. P. Trevino, J. Tang, and H. Liu, "Feature selection: A data perspective," *ACM Computing Surveys*, vol. 50, no. 6, pp. 94:1–94:45, 2017, accessed: Dec. 9, 2025. [Online]. Available: <https://doi.org/10.1145/3136625>
- [9] E. Kavlakoglu and V. Winland, "What is K-means clustering?" IBM Think Blog, accessed: Dec. 9, 2025. [Online]. Available: <https://www.ibm.com/think/topics/k-means-clustering>
- [10] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987, accessed: Dec. 9, 2025. [Online]. Available: [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- [11] T. M. Kodinariya and P. R. Makwana, "Review on determining number of cluster in K-means clustering," *International Journal of Advance Research in Computer Science and Management Studies*, vol. 1, no. 6, pp. 90–95, 2013, accessed: Dec. 9, 2025. [Online]. Available: https://www.ijarcsms.com/docs/paper/4_v01i1_issue6/Review-on-Determining-Number-of-Cluster.pdf
- [12] scikit-learn developers, "Selecting the number of clusters with silhouette analysis on KMeans clustering," scikit-learn documentation, accessed: Dec. 9, 2025. [Online]. Available: https://www.scikit-learn.org/stable/auto_examples/cluster/plot_kmeans_silhouette_analysis.html
- [13] S. Juanita and R. D. Cahyono, "K-means clustering with comparison of elbow and silhouette methods for medicines clustering based on user reviews," *Jurnal Teknik Informatika (JUTIF)*, vol. 5, no. 1, pp. 283–289, 2024, accessed: Dec. 9, 2025. [Online]. Available: <https://doi.org/10.52436/1.jutif.2024.5.1.1349>
- [14] DataCamp, "Hierarchical clustering: Concept overview with examples," DataCamp tutorial, accessed: Dec. 9, 2025. [Online]. Available: <https://www.datacamp.com/tutorial/hierarchical-clustering>
- [15] jjmewtw, "Clustering: K-means, hierarchical, DBSCAN, EMA," Kaggle notebook, 2020, accessed: Dec. 9, 2025. [Online]. Available: <https://www.kaggle.com/code/jjmewtw/clustering-k-means-hierarchical-debscan-ema>
- [16] L. Lerato and T. R. Niesler, "Cluster size management in multi-stage agglomerative hierarchical clustering of acoustic speech segments," *CoRR*, vol. abs/1810.12744, 2018, accessed: Dec. 9, 2025. [Online]. Available: <https://arxiv.org/abs/1810.12744>